

【書類名】 明細書

【発明の名称】 候補演算子絞り込み方法

【技術分野】

【0001】

本発明は、候補演算子絞り込み方法に関する。

【背景技術】

【0002】

近年、AI (Artificial Intelligence) を搭載する機器が増えている。AIにおけるニューラルネットワークは、例えば、複数のネットワーク層を有し、各ネットワーク層が複数のニューロンを有し、各ニューロンが前段のネットワーク層の複数のニューロンの出力を入力し、複数の入力とその重みを積和演算する。これらのニューラルネットワークにおける演算を専用で実行するニューラルネットワークプロセッサユニット (NPU: Neural network Processor Unit) が存在する。NPUは、ニューロンの演算を行う演算子と重みなどを記憶するメモリを有する複数のニューラルネットワークコアをネットワーク上に接続し、互いに入出力を行うことで、ターゲットとなるニューラルネットワークの機能を実現する。

【0003】

NPUに関する技術としては、例えば、以下に開示されている。

【先行技術文献】

【特許文献】

【0004】

【特許文献1】 特表2020-517006号公報

【発明の概要】

【発明が解決しようとする課題】

【0005】

しかし、NPUは、演算の実行において多大な電力を使用する場合がある。そのため、NPUは、一部又は全部の演算子を、近似演算子などの低電力の演算子に置換することが検討される。ただし、近似演算子は、その種別によって、演算精度や消費電力に差異がある。また、近似演算子は、非常に多くの種別が存在する。このことから、演算子の置換において、適切な近似演算子の選択を行うことは困難である。

【0006】

そこで、一開示は、演算子の置換において、非常に多くの近似演算子から候補となる近似演算子を抽出する候補演算子絞り込み方法を提供する。

【課題を解決するための手段】

【0007】

一開示は、置き換え対象の演算子と同じ演算を行う複数の一次候補演算子の演算精度及び消費電力を評価し、前記演算精度及び前記消費電力に応じて、前記複数の一次候補演算子を複数のランクに分類し、同一ランクに属する前記一次候補演算子を比較したとき、前記演算精度が高い場合、前記消費電力も高いという関係が成立し、最も優秀なランクに属する前記一次候補演算子のうち、第1閾値未満の演算精度である前記第1候補演算子と、前記第1閾値以上の演算精度かつ最も演算精度が低い前記一次候補演算子とを、二次候補演算子とし、前記二次候補演算子から、置き換えを行う演算子を選択する。

【発明の効果】

【0008】

一開示は、演算子の置換において、非常に多くの近似演算子から候補となる近似演算子を抽出することができる。

【図面の簡単な説明】

【0009】

【図1】 図1は、NPU10の構成の例を示す図である。

【図2】 図2は、ニューラルネットワークコア100の構成の例を示す図である。

【図3】図3は、近似演算子置換処理部のソフトウェア構成の例を示す図である。

【図4】図4は、近似演算子置換処理S10の処理フローチャートの例を示す図である。

【図5】図5は、近似演算子の評価の例を示す図である。

【図6】図6は、ランク分類の例を示す図である。

【図7】図7は、候補集合1008の例を示す図である。

【発明を実施するための形態】

【0010】

〔第1の実施の形態〕

第1の実施の形態について説明する。

【0011】

<NPUの構成例>

NPU10の構成例について説明する。図1は、NPU10の構成の例を示す図である。NPU10は、複数のニューラルネットワークコア100を有する。

【0012】

ニューラルネットワークコア100それぞれは、ニューラルネットワーク内のニューロンの集合に対応し、他のニューラルネットワークコアと接続して、データの入出力を実行する。

【0013】

CPU200 (Central Processer Unit) は、NPU10に演算を実行させるプロセッサである。

【0014】

図2は、ニューラルネットワークコア100の構成の例を示す図である。ニューラルネットワークコア100は、ニューラルアレイ101、メモリ103、及びネットワークインタフェース105を有する。

【0015】

ニューラルアレイ101は、ニューロンが行う演算を実行する演算子の配列である。ニューラルアレイ101は、例えば、複数の入力データと重みを積和演算し、出力する。ニューラルアレイ101は、複数の演算子 (SN: Spiking Neuron) 102を有する。ニューラルアレイ101は、複数の演算子を組み合わせることで、ニューロンが行う演算を実現する。

【0016】

メモリ103は、重みなどを記憶する記憶部である。メモリ103は、それぞれに重みを記憶する複数のメモリバンク (WMB: Weight Memory Bank) 104を有する。ニューラルネットワークコア100は、演算において重みを使用し、演算結果に応じて重みを更新する。

【0017】

ネットワークインタフェース105は、ニューラルネットワークコア100間、及びCPU200と接続し、通信を行う装置である。ニューラルネットワークコア100は、ネットワークインタフェース105を介して、データの入出力を行う。

【0018】

<近似演算子置換処理>

NPU10の一部又は全部の演算子を、近似演算子に置換する (置き換える) 近似演算子置換処理S10について説明する。なお、置換する演算子は、近似演算子に限られないが、以下の説明においては、近似演算子に置換するものとして説明する。

【0019】

<1. 近似演算子置換処理S10の処理部>

近似演算子置換処理S10は、例えば、所定のプログラムをプロセッサにより実行することで構築された各処理部において実行される。

【0020】

図3は、近似演算子置換処理部のソフトウェア構成の例を示す図である。近似演算子置換処理部1000は、近似演算子全集合生成部1001、近似演算子評価部1002、ランク分類部1003、候補集合生成部1004、及び近似演算子選択部1005を有する。また、近似演算子置換処理部1000における各処理部は、全集合1006、全評価結果1007、及び候補集合1008を、参照及び／又は更新する。

【0021】

近似演算子全集合生成部1001は、近似演算子の全集合1006を生成する。全集合1006は、使用可能な（評価可能な）演算子で、置換の候補となる演算子の全てを含む。全集合1006は、例えば、行いたい演算の種別ごとに存在する。また、全集合1006における候補とは、以下に説明する候補集合の候補を選択する前段階の候補を示し、例えば、一般に入手可能な演算子を示す。

【0022】

近似演算子評価部1002は、全集合に含まれる近似演算子进行评估し、全評価結果1007を生成する。全評価結果は、全ての近似演算子の性能評価の結果であり、例えば、演算品質や消費電力などを含む。

【0023】

ランク分類部1003は、全評価結果1007に含まれる近似演算子をランク分類する。

【0024】

候補集合生成部1004は、ランク分類された近似演算子から、特定のランク（例えば、最も優秀なランク）の近似演算子を抽出し、さらに、所定の基準に応じて抽出した近似演算子から一部の演算子を除外した、候補集合1008を生成する。候補集合1008は、置換候補となる近似演算子を含むデータベースである。

【0025】

近似演算子選択部1005は、候補集合1008から、置換する近似演算子を選択する。近似演算子選択部1005は、置換する近似演算子の最適な組み合わせの選択を、例えば、遺伝的アルゴリズムや他の最適化方法などを用いて決定する。

【0026】

<2. 近似演算子置換処理S10の処理フローチャート>

近似演算子置換処理S10の処理フローチャートについて説明する。図4は、近似演算子置換処理S10の処理フローチャートの例を示す図である。以下、近似演算子置換処理S10は、近似演算子置換処理部1000によって実行されるものとして説明するが、各処理が近似演算子置換処理部1000に含まれる各部において実行されてもよい。

【0027】

近似演算子置換処理部1000は、置換対象となる近似演算子を抽出し、全集合1006を生成する（S101）。全集合1006は、例えば、近似演算子の一覧などの情報から生成され、近似演算子の情報は、近似演算子を販売する企業の資料や、他のプロセッサユニットで使用されている演算子の情報などから取得する。

【0028】

近似演算子置換処理部1000は、全集合1006に含まれる近似演算子の評価を実施する（S102）。図5は、近似演算子の評価の例を示す図である。

【0029】

近似演算子置換処理部1000は、全集合1006から、近似演算子を抽出する（S102-1）。近似演算子置換処理部1000は、抽出した近似演算子进行评估用アプリケーションに実装する（S102-2）。近似演算子置換処理部1000は、実装した評価用アプリケーションを実行し、演算結果を得て、全評価結果1007を更新する（S102-3）。

【0030】

評価の対象は、例えば、演算精度及び消費電力である。演算精度は、例えば、ロス率である。ロス率は、演算に失敗し、正しい演算結果（数値）を得られない確率であり、低い

ほど近似演算子の演算精度が高いとみなすことができる。

【0031】

近似演算子置換処理部1000は、全集合1006に含まれる全ての近似演算子に対して評価を実施し、全ての近似演算子の評価結果を含む全評価結果1007を生成する（S102-3）。

【0032】

図4の処理フローチャートに戻り、近似演算子置換処理部1000は、全評価結果1007に含まれる近似演算子を、ロス率及び消費電力に基づき、ランク分類する（S103）。図6は、ランク分類の例を示す図である。近似演算子置換処理部1000は、例えば、縦軸をロス率、横軸を消費電力として、全評価結果に含まれる近似演算子をプロットする（S103-1）。

【0033】

近似演算子置換処理部1000は、プロットした近似演算子を、ロス率が低く、かつ消費電力が低いものから順にランク分けを行う（S103-2）。ランク1は、最もロス率が低く、かつ消費電力も低い、最も優秀なランクとなる。ランクの数値は低いほど、演算精度および消費電力が良好となり、優れたランクとなる。

【0034】

ランク分類は、例えば、非支配ソート（Non-dominated Sorting）を用いて、品質（演算精度）及び消費電力の優劣関係でソートを行う。同一ランク内の近似演算器は、例えば、他の近似演算器より品質が優れている場合、消費電力は劣るという関係である。また、ランク x （ x は整数）の近似演算器は、ランク y （ y は整数。 $y > x$ ）の近似演算器よりも、品質及び消費電力で優れているという関係である。例えば、ランク x のある品質の近似演算子は、ランク y の同一品質の近似演算子よりも、消費電力が優れている。また、例えば、ランク x のある消費電力の近似演算器は、ランク y の同一商品電力の近似演算器よりも、品質が優れている。

【0035】

なお、非支配ソートによるランク分けは、あくまで一例であり、別のソート方法やランク分け方法を用いてもよい。ランク分けは、上記に示した関係が保たれるのであれば、他のソート方法やランク分けを用いてもよい。また、全評価結果1007のプロットについては、全評価結果1007のデータを直接ソート及びランク分けが可能な場合、省略されてもよい。

【0036】

図4の処理フローチャートに戻り、近似演算子置換処理部1000は、ランク分けの結果から、置換候補となる近似演算子の候補集合1008を生成する（S104）。

【0037】

図7は、候補集合1008の例を示す図である。近似演算子置換処理部1000は、ランク1の近似演算子を、品質が良好な順にソートしたランク1評価結果から、候補集合1008を生成する（S104-1）。候補集合1008は、品質の良い順に並べ替えることで、同時に消費電力の悪い順に並べ替えられる。

【0038】

近似演算子置換処理部1000は、ランク1評価結果から、品質閾値を超える（品質閾値以上の）近似演算子のうち最も品質が劣っている（消費電力が少ない）近似演算子を残り、品質閾値を超える他の近似演算子を除去したものを、候補集合1008として生成する（S104-1）。すなわち、候補集合1008は、ランク1に属する近似演算子であって、品質閾値未満の近似演算子と、品質閾値以上の近似演算子のうち最も品質が低い近似演算子とを、含む集合である。

【0039】

図7において、近似演算子置換処理部1000は、ランク1評価結果から、品質閾値70%より大きいAO1、AO2、AO3のうち、最も品質が低いAO3を残し、AO1及びAO2を削除したものを、候補集合1008として生成する。すなわち、ランク1評価

結果から、品質閾値より高い近似演算子1つを残して、残した近似演算子よりも品質が良好な近似演算子を削除したものが、候補集合1008となる。

【0040】

品質閾値は、例えば、ニューラルネットワークプロセッサユニット10全体や、ニューロン単位において、要求される品質に基づく数値である。品質閾値は、例えば、一つの近似演算子として担保されれば十分であるという品質数値である。また、品質閾値は、例えば、ニューラルネットワークプロセッサユニット10全体として要求される最低限の品質数値である。

【0041】

図4の処理フローチャートに戻り、近似演算子置換処理部1000は、候補集合1008から、置換する近似演算子を選択し（S105）、処理（近似演算子を用いたNPU10の設計）を終了する。

【0042】

近似演算子置換処理部1000は、候補集合1008から近似演算子を選択することで、必要以上に品質が良好な近似演算子を除外でき、消費電力を抑えた近似演算子を選択することができる。すなわち、近似演算子置換処理部1000は、必要以上に高品質な近似演算子を使用することによる、消費電力の増加を抑制することができる。

【0043】

〔その他の実施の形態〕

近似演算子置換処理部1000は、置換する近似演算子の選択において、候補集合1008の最も品質が良好な近似演算子を選択すればよい。これにより、NPU10は、要求品質を満たし、かつ必要以上の品質を実現することによる過剰な消費電力を消費しないものとなる。

【0044】

しかし、近似演算子置換処理部1000は、例えば、全ての近似演算子を、候補集合1008の最も品質が良好な近似演算子としなくてもよい。近似演算子置換処理部1000は、例えば、NPU10全体としての消費電力の上限が決まっているなど、消費電力に関する条件を満たさなければならない場合、品質は劣るが、消費電力が少ない近似演算子を、一部選択してもよい。

【0045】

また、第1の実施の形態における近似演算子置換処理S10は、NPU10以外にも、例えば、GPU（Graphics Processing Unit）などの特定の処理を行うためのプロセッサユニットに用いられてもよい。

【0046】

また、NPU10は、近似演算子と正規の演算子の両方が設置されてもよい。そして、NPU10は、使用可能な電力に応じて、近似演算子と正規演算子を使い分けられてもよい。このような、近似演算子と正規演算子の両方を有するNPU10における近似演算子の選択においても、第1の実施の形態における近似演算子置換処理を用いることができる。なお、NPU10に近似演算子と正規の演算子の両方が設置される場合、NPU10の面積が大きくなるため、NPU10を設置する機器における設置個所の面積の条件を別途満たす必要がある。

【符号の説明】

【0047】

10 : ニューラルネットワークプロセッサユニット
 100 : ニューラルネットワークコア
 101 : ニューラルアレイ
 103 : メモリ
 105 : ネットワークインタフェース
 200 : CPU
 1000 : 近似演算子置換処理部

- 1 0 0 1 : 近似演算子全集合生成部
- 1 0 0 2 : 近似演算子評価部
- 1 0 0 3 : ランク分類部
- 1 0 0 4 : 候補集合生成部
- 1 0 0 5 : 近似演算子選択部
- 1 0 0 6 : 全集合
- 1 0 0 7 : 全評価結果
- 1 0 0 8 : 候補集合

【書類名】 特許請求の範囲

【請求項 1】

複数の演算子を有するプロセッサユニットにおいて、前記演算子の一部又は全部を他の演算子に置き換えるときの、置き換え候補となる候補演算子を絞り込む方法であって、置き換え対象の演算子と同じ演算を行う複数の一次候補演算子の演算精度及び消費電力を評価し、

前記演算精度及び前記消費電力に応じて、前記複数の一次候補演算子を複数のランクに分類し、

同一ランクに属する前記一次候補演算子を比較したとき、前記演算精度が高い場合、前記消費電力も高いという関係が成立し、

最も優秀なランクに属する前記一次候補演算子のうち、第 1 閾値未満の演算精度である前記第 1 候補演算子と、前記第 1 閾値以上の演算精度かつ最も演算精度が低い前記一次候補演算子とを、二次候補演算子とし、

前記二次候補演算子から、置き換えを行う演算子を選択する候補演算子絞り込み方法。

【請求項 2】

前記置き換え候補となる演算子は、近似演算子である

請求項 1 記載の候補演算子絞り込み方法。

【請求項 3】

前記ランクに分類する処理は、非支配ソートを用いて行う

請求項 1 記載の候補演算子絞り込み方法。

【請求項 4】

前記第 1 閾値は、前記プロセッサユニットが要求される品質条件に応じて設定される

請求項 1 記載の候補演算子絞り込み方法。

【請求項 5】

前記評価は、前記近似演算子を評価用アプリケーションに設置し、実行される

請求項 1 記載の候補演算子絞り込み方法。

【請求項 6】

前記アプリケーションが算出する値が正しくない確率が低いほど、前記演算精度は高いとみなされる

請求項 5 記載の候補演算子絞り込み方法。

【書類名】要約書

【要約】

【課題】演算子の置換において、非常に多くの近似演算子から候補となる近似演算子を抽出することができる。

【解決手段】


置き換え対象の演算子と同じ演算を行う複数の一次候補演算子の演算精度及び消費電力を評価し、前記演算精度及び前記商品電力に応じて、前記複数の一次候補演算子を複数のランクに分類し、同一ランクに属する前記一次候補演算子を比較したとき、前記演算精度が高い場合、前記消費電力も高いという関係が成立し、最も優秀なランクに属する前記一次候補演算子のうち、第1 閾値未満の演算精度である前記第1 候補演算子と、前記第1 閾値以上の演算精度かつ最も演算精度が低い前記一次候補演算子とを、二次候補演算子とし、前記二次候補演算子から、置き換えを行う演算子を選択する。

【選択図】図 6

【書類名】図面


【図 1】

ニューラルネットワークプロセッサユニット10




【図 2】


ニューラルネットワークコア100




【図 3】




【図 4】




【図 5】



【図 6】



【図 7】



THE JOURNAL OF THE AMERICAN MEDICAL ASSOCIATION
PUBLISHED WEEKLY
CHICAGO, ILL., MAY 1, 1919. Vol. 34, No. 19
Subscription price, \$5.00 per annum in advance.
Single copies, 15 cents.

THE JOURNAL OF THE AMERICAN MEDICAL ASSOCIATION
PUBLISHED WEEKLY
CHICAGO, ILL., MAY 1, 1919. Vol. 34, No. 19
Subscription price, \$5.00 per annum in advance.
Single copies, 15 cents.

THE JOURNAL OF THE AMERICAN MEDICAL ASSOCIATION
PUBLISHED WEEKLY
CHICAGO, ILL., MAY 1, 1919. Vol. 34, No. 19
Subscription price, \$5.00 per annum in advance.
Single copies, 15 cents.