

【書類名】明細書

【発明の名称】ニューラルネットワークプロセッサおよびプルーニング対象のニューロンを選択する方法

【技術分野】

【0001】

本発明は、ニューラルネットワークプロセッサおよびそのニューラルネットワークプロセッサのニューロンを動的にプルーニングする方法であって、プルーニング対象のニューロンを選択する方法に関する。

【背景技術】

【0002】

ニューラルネットワークプロセッサ（以下NNプロセッサと称する場合がある。）は、ニューラルネットワークモデル（以下NNモデルと称する場合がある。）の推論計算を実行するプロセッサである。NNモデルは、入力データを受信する複数の第1のニューロン（ノード）と、複数の第1のニューロンとそれぞれのシナプス（エッジ）を介して接続された第2のニューロンとを有する。このような構成は、畳込演算層や全結合層と呼ばれる。そして、NNモデルでは、複数の第1のニューロンの入力データとシナプスの重みとが積和演算され、第2のニューロンの活性化関数が積和演算結果に基づき算出する活性化出力が第2のニューロンの出力となる。シナプスの重みは、ニューラルネットワークの深層学習でファインチューニングされるパラメータの一つである。

【0003】

NNプロセッサは、複数のネットワーク層を有し、各ネットワーク層が複数のニューロンを有し、各ニューロンは、前段のネットワーク層の複数のニューロンの出力を入力とし、その複数の入力とその重みを積和演算する積和演算器と、前記積和演算器の出力を入力して活性化出力を出力する活性化関数器とを有する。

【0004】

NNプロセッサは、例えばニューロンを模倣したニューロモルフィックプロセッサである。但し、NNプロセッサは、ニューロモルフィックプロセッサに限定されず、複数のニューロンをネットワーク状に接続した演算プロセッサであればよい。

【0005】

NNプロセッサは、通常、メインプロセッサとインターチップリンクを介して接続され、メインプロセッサからの複数の入力値を入力し、複数のネットワーク層が複数の入力値を入力し、各ネットワーク層のニューロンが演算を実行する（特許文献1及び2）。

【先行技術文献】

【特許文献】

【0006】

【特許文献1】特開2024-82516号公報

【特許文献2】特開2025-146538号公報

【非特許文献】

【0007】

【非特許文献1】Yuga, Hanyu and Khanh N. Dang. "EnsembleSTDP: Distributed in-situ Spike Timing Dependent Plasticity Learning in Spiking Neural Networks." 2024 IEEE 17th International Symposium on Embedded Multicore/Many-core Systems-on-Chip (MCSoc) (2024): 434-440.

【発明の概要】

【発明が解決しようとする課題】

【0008】

NNプロセッサがエッジ環境化でその演算処理を実行する場合、エッジ環境での供給電力の変動に対応して、その演算処理を適切な精度で実行することが要求される。電力変動に伴う電源電圧の低下に対応して、複数のニューラルネットワーク（以下NN）をより単純なニューラルネットワークモデルに切り替えることが行われるが、この手法は複雑であり、

電源電圧の低下に適応した解決手段ではない。

【0009】

また、NNモデル内の一部の回路をプルーニング（剪定）することで消費電力を抑制することが知られているが、複雑でないNNモデルに適用されている。

【0010】

そこで、本発明の目的は、電源電圧の変動に適応して、動的にそして効果的にプルーニング対象のニューロンが選択されてプルーニングされるニューラルネットワークプロセッサ及びプルーニング対象のニューロンを選択する方法を提供することにある。

【課題を解決するための手段】

【0011】

上記目的を達成するための本発明のニューラルネットワークプロセッサは、ネットワークオンチップを介して接続する複数のニューラルコンピューティングコアを有するニューラルネットワークプロセッサであって、各ニューラルコンピューティングコアは、演算器を有する複数のニューロンと、各ニューロンの重みデータを記憶する内部メモリとを含み、供給電力の大きさに応じて、プルーニングするニューロンの個数が決定され、前記複数のニューロンのうちのニューロン同士の所定の類似度に基づいて、前記ニューロンの個数分のプルーニングするニューロンが選択され、その選択されたニューロンとその重みデータがプルーニングされることを特徴とする。

【0012】

本発明のプルーニング対象のニューロンを選択する方法は、ネットワークオンチップを介して接続する複数のニューラルコンピューティングコアを有するニューラルネットワークプロセッサであって、各ニューラルコンピューティングコアは、演算器を有する複数のニューロンと、各ニューロンの重みデータを記憶する内部メモリとを含む前記ニューラルネットワークプロセッサにおける、前記複数のニューロンのうちプルーニングするニューロンをコンピュータ装置により選択する方法において、前記コンピュータ装置は、前記ニューラルネットワークプロセッサへの供給電力の大きさに応じて、実行されるモデルのサイズを決定する第1工程と、

前記モデルのサイズに基づいて、プルーニングするニューロンの個数を決定し、前記複数のニューロンのうちのニューロン同士の所定の類似度に基づいて、前記ニューロンの個数分のプルーニングするニューロンを選択する第2工程と、前記プルーニングするニューロンの情報を前記ニューラルネットワークプロセッサに送信し、前記ニューラルネットワークプロセッサに前記選択されたニューロンをプルーニングさせる第3工程とを実行することを特徴とする。

【発明の効果】

【0013】

本発明によれば、供給電力の変動に応じて、プルーニング対象とするニューロンを適切に選択することができる。ニューラルネットワークプロセッサの消費電力が供給電力を上回らないように、動的に適応的にニューロンのプルーニングを実行することができる。

【図面の簡単な説明】

【0014】

【図1】ニューラルネットワークプロセッサ（NNプロセッサ）の構成例を示す図である。

【図2】ニューラルネットワークの概略モデル例を示す図である。

【図3】AIシステムの全体構成を示す図である。

【図4】動的プルーニング指示情報の送信処理のフローチャートを示す。

【図5】動的プルーニング指示情報の生成処理のフローチャートを示す。

【図6】動的プルーニング指示情報の生成処理に従った具体例を示す。

【図7】動的プルーニングの動作例を示す図である。

【図8】ニューロンのプルーニングまたはアンプルーニングによるノードの消費電力とノードへの供給電力の関係を示す図である。

【発明を実施するための形態】

【0015】

以下、図面を参照して本発明の実施の形態について説明する。しかしながら、かかる実施の形態例が、本発明の技術的範囲を限定するものではない。本発明の実施の形態について、具体的な図に基づいて説明する。

【0016】

ニューラルネットワークプロセッサ（以下、NNプロセッサと称する場合がある。）は、入力データとニューラルネットワークの重み等のパラメータの畳み込み演算を実行し、その重みのデータはNNプロセッサの内部メモリに記憶されている。本実施の形態例では、アプリケーションプログラム（以下、「アプリケーション」と称する）実行中において、NNプロセッサの内部メモリに記憶される重みデータを再ダウンロードして書き換える処理、及びNNプロセッサに供給される電力の大きさに応じて、この重みデータを再ダウンロードするタイミング周期を、算出する処理について説明する。

【0017】

図1は、ニューラルネットワークプロセッサ（NNプロセッサ）の構成例を示す図である。また、図2は、ニューラルネットワークの概略モデル例を示す図である。

【0018】

図1に示したNNプロセッサ101は、一例として、ニューロモーフィックプロセッサであり、マトリクス状に配置された複数のニューラルコンピューティングコア102と、コア間の通信を可能にする二次元メッシュ状のネットワークオンチップ103とを有する。NNプロセッサ101は、チップ間接続108を介してホストプロセッサチップ109に接続される。ホストプロセッサチップ109は、NNプロセッサ101にアプリケーション（モデルと称する場合もある）を実行させるプロセッサである。

【0019】

ニューラルコンピューティングコア102は、ネットワークインターフェース（NI）104と、重みメモリ（WM）105と、それぞれ演算器を有するニューロンアレイ（NA）106を有する。ネットワークインターフェース104は、ルータ107に接続され、ニューラルコンピューティングコア102とネットワークオンチップ103の間の通信のインターフェース処理を実行する。各ニューラルコンピューティングコア102に設けられたルータ107は、ネットワークオンチップ103に設けられ、ネットワークオンチップ103を伝播する通信を宛先のコアの方向にルーティングする。更に、ルータ107は、コア宛の通信をそのコアの方向にルーティングする。

【0020】

前述のとおり、コアのネットワークインターフェース104が、ネットワークオンチップ103からルータ107によりルーティングされた入力を受信する。この入力は、例えば、ホストプロセッサ109が命令をデコードして発行した演算要求である。ネットワークオンチップ103は、受信した演算要求をデコードし、ニューロンアレイ106と重みメモリ105にデコードされた要求を送信する。それぞれの要求に基づいて、重みメモリ105は重みを読み出してニューロンアレイに送信し、ニューロンアレイ106は、要求に含まれる入力データと読み出された重みデータについて、要求に含まれた演算を実行する。演算結果は符号化されてルータ107に返信され、次の宛先のニューラルコンピューティングコア102に転送される。

【0021】

ニューロンアレイ106は、複数（N個）の物理ニューロン110を有し、識別番号 $SN_1 \sim SN_N$ にインデックス付けされる。複数の物理ニューロン110は、ニューラルネットワーク内の複数のニューロンに対応付けられる。重みメモリ105は、複数の重みメモリブロック（WMB）111を有し、各メモリブロック111に記憶される重みデータは、ニューラルネットワーク内のニューロン間のエッジに対応付けられる。重みメモリ105は所定の低電圧下でも動作する。これらの対応付けはホストプロセッサチップ109により行われ、ホストプロセッサチップ109は、この対応付けに基づいて演算要求を発行し、演算要求の宛先のニューラル

コンピューティングコア102に送信する。このように、ホストプロセッサチップ109は、NNプロセッサ101にニューラルネットワークのニューロン間を接続するエッジの重みをマッピングし、NNプロセッサ101にニューラルネットワークの学習や推論の演算など各種アプリケーションを実行させる。

【0022】

図2に示すように、ニューラルネットワーク201は複数のニューロンモデル202で構成される。ニューラルネットワーク201は有向グラフとして表現され、各ノードはニューロン202に対応する。矢印206は2つのニューロン202間の通信を表す。この通信は、あるニューロン202の出力データ207を別のニューロンの入力データ203として伝達する。演算器を有するニューロン202内部では、入力蓄積関数204を用いて蓄積され、出力は活性化関数205を用いて決定される。ここで開示するニューラルネットワーク201は、特定の有向グラフ、活性化関数、蓄積関数に限定されない。

【0023】

図1に戻って、各物理ニューロン110は、演算器を有し、要求された演算を実行する。物理ニューロン110は、ネットワークインターフェース104から入力データ等を含む要求を受信し、重みメモリ105から演算要求に基づいて読み出された重みデータを受信する。そして物理ニューロン110は、入力データと重みデータを使用して要求された演算を実行する。

【0024】

要求された演算が畳み込み演算の場合、演算を実行する物理ニューロン110は、入力ニューロンから送信された入力データと、入力ニューロンの重みデータを受信する。そして、演算を実行する物理ニューロン110は、入力データと重みデータの積和演算を実行し、ニューロンモデルの活性化関数に積和演算結果を入力して実行し、その演算結果を出力する。物理ニューロンの演算は、例えばNNプロセッサ内のクロックサイクルに同期して実行され、演算結果は次の演算実行対象の物理ニューロンに送信される。

【0025】

即ち、M個の入力ニューロンから送信された入力データを $input_1 \sim input_M$ 、各エッジの重みを $weight_1 \sim weight_M$ 、活性化関数を $f_{activation}$ とすると、演算を実行する物理ニューロンの出力 $output$ は次のとおりである。

$$output = f_{activation} \left(\sum_{i=1-M} input_i * weight_i \right)$$

ここで、Mは入力データの数、重みの数である。活性化関数はReLU関数などである。

【0026】

NNプロセッサは、AIシステムの各ノード（エッジ）及びそれと通信回線を通じて接続するクラウドサーバにそれぞれ搭載される。すなわち、AIシステムを構成するノード（エッジ）及びクラウドサーバはNNプロセッサを搭載したコンピュータ装置である。

【0027】

図3は、AIシステムの全体構成を示す図である。AIシステムは、複数のノード（エッジ）301及びクラウドサーバ（以下、サーバと称する場合がある）302を有して構成される。ノード301とサーバ302は無線通信303を介して接続されている。各ノード301またはサーバ302には、自ら収集した、または外部ソースから保存された独自のローカルデータ304を記憶している。また、各ノード301には、それぞれ独自のニューラルネットワークで構成されるアプリケーション（モデル）305を有し、各モデル305は、複数のニューロン307とパラメータとしての重みデータ306で構成される。

【0028】

本実施の形態例では、ノード動作中における電源電圧の変動に適応可能とし、供給電力（電源電圧）の大きさに応じて、プルーニングするニューロンを選択し、その選択されたニューロンをプルーニングすることで、ノードの消費電力を供給電力の範囲内に調整するための方法を提供する。

【0029】

クラウドサーバ302では、各ノード301からのモデル305を統合してモデル305を生成し、

サーバ302が生成したモデル305を各ノード301に配信する(ブロック311)。図3では、ノード301の当初のモデルとサーバ302が生成するモデルに同一符号を付している。また、図3において、サーバ302の機能・プロセスがブロック化して示される。サーバ302が生成するモデル305も複数のニューロン307とパラメータとしての重みデータ306を有する。クラウドサーバ302は、モデル305の生成とともに、供給電力(電源電圧)の変動に応じて、動的にプルーニングされるニューロンの指示情報(動的プルーニング指示情報)を生成し(ブロック312)、生成した305とともに配信する。動的プルーニング指示情報は、プルーニングされるニューロンの数、プルーニングのために選択されたニューロン、プルーニングされる順序などの情報を含む。動的プルーニング指示情報の詳細については、さらに後述する。

【0030】

図4は、動的プルーニング指示情報の送信処理のフローチャートを示す。まず、各ノード301において、モデル305をトレーニングする(S401)。次に、各ノード301は、モデル305をサーバ302にアップロードし、サーバ302は、各ノードからのモデル305を統合して、サーバ側でのモデル305を生成する(S402)。なお、この図4のS402の処理は、図3のブロック311に対応する。

【0031】

サーバ302は、各ノードにおけるモデルのサイズを決定する(S403)。モデルのサイズは、モデルを構成するニューロン全体の数であって、ノードに供給される電力の大きさに応じて、モデルのニューロン数が設定される。例えば、100%の供給電力、すなわち正常な供給電力(電源電圧)に対して、モデルのニューロン数は最大となり、供給電力の低下に伴い、その供給電力の大きさに従って段階的にニューロン数を少なくしたモデルのサイズが設定される。例えば、例えば、正常値100%の供給電力に対して、各ノードの供給電力を99-80%、79-60%、59-30%、30-10%、9%以下に分類した各供給電力の大きさに対応するモデルのニューロン数が設定される。そして、サーバ302は、各ノードで予測される供給電力に対応するモデルのサイズが決定される。ノードの消費電力が供給電力を上回らない程度のニューロン数となるように設定され、100%の場合のモデルサイズのニューロン数に対して、供給電力の減少に応じて、プルーニングするニューロンの個数を設定することで、モデルのサイズが決定される。すなわち、モデルのサイズは、プルーニングするニューロンの個数と対応関係にある。各ノードの電力供給状況は外部から適宜取得される。

【0032】

サーバ302は、各ノードに対して決定されたモデルのサイズに対応する動的プルーニング指示情報を生成し(S404)、サーバが生成したモデル305とノード毎の動的プルーニング情報を各ノードに配信する(S405)。この図4のS405の処理は、図3のブロック312に対応する。

【0033】

図5は、動的プルーニング指示情報の生成処理のフローチャートを示し、図6は、その生成フローに従った処理例を示す。図6において、当該図5の生成フローに従った処理例がブロック化して示される。まず、モデル305を構成する複数のニューロンについて、2つのニューロンの全ての組み合わせのペア(ニューロンペア Pair_p)を生成する(S501)。図6において、例えば、あるモデルにおけるK個のニューロンWが示され(ブロック600)、図5及び図6のS501において、K個のニューロンWにおけるすべての組み合わせのニューロンペア(W_1, W_2)、(W_1, W_3)、 $\dots$ 、(W_1, W_K)、 $\dots$ 、(W_{K-1}, W_K)が示される(ブロック601)。すべての組み合わせのニューロンペアの数をp個とする。

【0034】

そして、各ニューロンペアについて、ニューロン間の類似度 $V_{\text{similarity}}$ を算出する(S502)。類似度は、ペアとなっている各ニューロンの重みデータの最小二乗誤差(MSE: Mean Square Error)により求められる。すなわち、 $V_{\text{similarity}, p} = \text{MSE}(\text{Pair}_p)$ が演算される。なお、最小二乗誤差に類似する他の関数を用いることもできる。図6には、S502の処理による各ペアの算出された類似度 $V_{\text{similarity}, 1}$ 、 $V_{\text{similarity}, 2}$ 、 $\dots$ 、 $V_{\text{similarity}, p}$ が示される。

y, p が示される(ブロック602)。各ペアにおけるニューロンが入力と出力を共有しない場合、類似度は最低値となる。共有する場合、上記最小二乗誤差(MSE)などを用いてその類似度を算出する。

【0035】

算出した類似度 $V_{\text{similarity}}$ が高い順にニューロンペアをソートし、類似度 $V_{\text{similarity}}$ が高い順にソートされたニューロンペアのリストを作成する(S503)。図6に、類似度 $V_{\text{similarity}}$ が高い順にソートされたニューロンペアのリストが例示される(ブロック603)。そして、類似度の高い順に上位からニューロンペアの片方をプルーニング対象のニューロンとして選択する(S504)(ブロック604)。ブロック604は、最も類似度が高いニューロンペア W_3, W_2 のうち W_3 がプルーニング対象のニューロンとして選択される例である。このとき、ペアのどちらのニューロンを選択してもよく、任意の一方が選択される。類似度 $V_{\text{similarity}}$ が高い順に並べられたニューロンペアのリストの上位から順に、各ニューロンペアの片方を選択していき、各ノードに対して決定されたモデルのサイズに応じたプルーニング対象のニューロンの個数分のニューロンが選択される(S505)。選択されたニューロンを識別するニューロンのインデックスが抽出される(S506)(ブロック606)。

【0036】

リスト上位から順にプルーニング対象のニューロンが選択されていく段階において、あるニューロンペアの一方のニューロンがリスト上位ですでに選択済みのニューロンである場合は、それを重複して選択せずに、そのニューロンペアからはプルーニング対象のニューロンは選択せず、次のニューロンペアに選択処理は移行する。このように、類似度が高い順にソートされたニューロンペアのリストの上位から順に、モデルのサイズに応じたニューロンの個数分だけ、プルーニング対象のニューロンが選択され、選択されたニューロンのインデックスが抽出される。動的プルーニング指示情報は、この選択された少なくとも一つのニューロン(プルーニング対象のニューロン)のインデックスを含む。

【0037】

このように、設定されたモデルのサイズに基づいて、プルーニングするニューロンの個数が決定され、モデルを構成する複数のニューロンのうちのニューロン同士の所定の類似度に基づいて、ニューロンの個数分のプルーニングするニューロンが選択される。

【0038】

図7は、動的プルーニングの動作例を示す図である。図7の例では、インデックス(3)のニューロンがプルーニングされる。ノード301は、配信されたモデルと動的プルーニング指示情報に基づいて、モデル305からインデックス(3)のニューロン307とその重みデータを削除し、モデル内で新しいニューラルネットワークを構築する。これにより、各ノードのモデルのサイズは、ノードへの供給電力に応じてクラウドサーバであらかじめ設定されたモデルサイズとなる。

【0039】

また、各ノードでモデルを実行中において、ノードへの供給電力の変動が予測される場合、例えば、供給電力が増加するまたは正常な供給電力値に戻ると予測されると、クラウドサーバ302は、モデルのサイズを再決定し、そのサイズに対応する動的プルーニング指示情報を再生成する。例えば、モデルのサイズはより大きくなるように決定され、プルーニング不要(プルーニング対象のニューロン数がゼロ)の動的プルーニング指示情報またはプルーニング対象のニューロンの数を減少させた動的プルーニング指示情報を生成し、再度ノードに配信し、ノードは、その動的プルーニング指示情報に従って、プルーニング(pruning)されたニューロンの一部または全部を復元する、すなわち、プルーニングが解除される(アンプルーニング:un-pruning)。

【0040】

必要に応じて、各ノードでモデルを実行中において、例えば、供給電力が低下すると予測される場合においても、クラウドサーバは、モデルのサイズを再決定し、そのサイズに対応する動的プルーニング指示情報を再生成する。例えば、モデルのサイズを小さくし、再決定されたモデルサイズに対応して、プルーニング対象のニューロンの数を増加させた

動的プルーニング指示情報を生成し、再度ノードに配信し、ノードは、その動的プルーニング指示情報に従って、さらに、ニューロンを追加的にプルーニングする。

【0041】

図8はニューロンのプルーニング(pruning)またはアンプルーニング(un-pruning)によるノードの消費電力とノードへの供給電力の関係を示す図である。図8(a)はノードへの供給電力が減少していく例であって、この場合、供給電力(Power supply)の減少に応じて、モデルのサイズを小さくし、上述の処理により、モデルのサイズに応じたニューロン数分のプルーニング対象のニューロンが選択され、その選択されたニューロンが削除されることにより、ノードの消費電力(Power Consumption)は減少し、供給電力を上回らないように調整される。図8(b)は、反対に、ノードへの供給電力(Power supply)が増加していく例であって、この場合、供給電力の増加に応じて、モデルのサイズを大きくし、上述の処理により、モデルのサイズに応じたニューロン数分のプルーニング対象のニューロンが選択されるが、その選択されたニューロンの数が減ることで、プルーニングされていたニューロンの少なくとも一部が復元される。これにより、ノードの消費電力(Power Consumption)は増大し、この場合も、供給電力を上回らないように調整される。

【0042】

本発明は、上記実施の形態に限定されるものではなく、本発明の分野における通常の知識を有する者であれば想到し得る、各種変形、修正を含む、本発明の要旨を逸脱しない範囲の設計変更があっても、本発明に含まれることは勿論である。

【符号の説明】

【0043】

101:ニューラルネットワークプロセッサ、102:ニューラルコンピューティングコア、103:ネットワークオンチップ、104:ネットワークインターフェース、105:重みメモリ、106:ニューロンアレイ、107:ルータ、108:チップ間接続、109:ホストプロセッサチップ、110:物理ニューロン、111:重みメモリブロック、201:ニューラルネットワーク、202:ニューロンモデル、203:入力データ、204:蓄積関数、205:活性化関数、206:矢印、207:出力データ、301:ノード(エッジ)、302:クラウドサーバ

【書類名】 特許請求の範囲**【請求項 1】**

ネットワークオンチップを介して接続する複数のニューラルコンピューティングコアを有するニューラルネットワークプロセッサであって、

各ニューラルコンピューティングコアは、演算器を有する複数のニューロンと、各ニューロンの重みデータを記憶する内部メモリとを含み、

供給電力の大きさに応じて、プルーニングするニューロンの個数が決定され、前記複数のニューロンのうちのニューロン同士の所定の類似度に基づいて、前記ニューロンの個数分のプルーニングするニューロンが選択され、その選択されたニューロンとその重みデータがプルーニングされることを特徴とするニューラルネットワークプロセッサ。

【請求項 2】

ネットワークオンチップを介して接続する複数のニューラルコンピューティングコアを有するニューラルネットワークプロセッサであって、各ニューラルコンピューティングコアは、演算器を有する複数のニューロンと、各ニューロンの重みデータを記憶する内部メモリとを含む前記ニューラルネットワークプロセッサにおける、前記複数のニューロンのうちプルーニングするニューロンをコンピュータ装置により選択する方法において、前記コンピュータ装置は、

前記ニューラルネットワークプロセッサへの供給電力の大きさに応じて、実行されるモデルのサイズを決定する第1工程と、

前記モデルのサイズに基づいて、プルーニングするニューロンの個数を決定し、前記複数のニューロンのうちのニューロン同士の所定の類似度に基づいて、前記ニューロンの個数分のプルーニングするニューロンを選択する第2工程と、

前記プルーニングするニューロンの情報を前記ニューラルネットワークプロセッサに送信し、前記ニューラルネットワークプロセッサに前記選択されたニューロンをプルーニングさせる第3工程とを実行することを特徴とする方法。

【請求項 3】

前記第2工程は、

前記複数のニューロンの中の2つのニューロンの組み合わせであるニューロンペアを複数個生成する処理と、

前記複数のニューロンペアについて、各ニューロンペアを構成する2つのニューロンの類似度を算出する処理と、

前記類似度の高い順に前記複数のニューロンペアをソートする処理と、

供給電力の大きさに応じて決定される前記モデルのサイズに基づいて、プルーニングするニューロンの数を決定する処理と、

前記類似度が高い順から当該プルーニングするニューロンの数分の前記ニューロンペアを選択し、そのニューロンペアのうちの一方を前記プルーニングするニューロンとして選択する処理とを含むことを特徴とする請求項2に記載の方法。

【請求項 4】

前記プルーニングするニューロンの数は、前記ニューラルネットワークプロセッサの消費電力が、供給電力を超えないように決定されることを特徴とする請求項3に記載の方法。

【請求項 5】

前記ニューラルネットワークプロセッサの消費電力が供給電力を超えない範囲で、プルーニングが解除され、プルーニングされたニューロンは復元されることを特徴とする請求項4に記載の方法。

【請求項 6】

ネットワークオンチップを介して接続する複数のニューラルコンピューティングコアを有するニューラルネットワークプロセッサであって、各ニューラルコンピューティングコアは、演算器を有する複数のニューロンと、各ニューロンの重みデータを記憶する内部メモリとを含む前記ニューラルネットワークプロセッサにおける、前記複数のニューロンの

うちプルーニングするニューロンをコンピュータ装置により選択させるコンピュータプログラムであって、

前記ニューラルネットワークプロセッサへの供給電力の大きさに応じて、実行されるモデルのサイズを決定する工程と、

前記モデルのサイズに基づいて、プルーニングするニューロンの個数を決定し、前記複数のニューロンのうちのニューロン同士の所定の類似度に基づいて、前記ニューロンの個数分のプルーニングするニューロンを選択する第2工程と、

前記プルーニングするニューロンの情報を前記ニューラルネットワークプロセッサに送信し、前記ニューラルネットワークプロセッサに前記選択されたニューロンをプルーニングさせる工程とをコンピュータ装置に実行させることを特徴とするコンピュータプログラム。

【書類名】 要約書


【要約】

【課題】 ニューラルネットワークプロセッサのニューロンのうちプルーニング対象となるニューロンを選択する方法を提供する。


【解決手段】 ネットワークプロセッサは、ネットワークオンチップを介して接続する複数のニューラルコンピューティングコアを有し、各ニューラルコンピューティングコアは、演算器を有する複数のニューロンと、各ニューロンの重みデータを記憶する内部メモリとを含み、供給電力の大きさに応じて、プルーニングするニューロンの個数が決定され、複数のニューロンのうちのニューロン同士の所定の類似度に基づいて、ニューロンの個数分のプルーニングするニューロンが選択され、その選択されたニューロンとその重みデータがプルーニングされる。

【選択図】 図 5


【図 2】




【図 3】




【図 4】




【図 5】



【図 6】





【図 8】

